3 조 데이터 분석 프로젝트

기말고사 성적과 관련된 요인 및 설명력 분석

장범진 · 김민재 · 최용준 · 김가람

(ITWILL- 빅데이터 분석 -56 기 -3 조)

CONTENTS

목차

01 분석 개요

02 데이터 전처리

03 EDA

04 모델링 및 평가

05 결론

06 참고문헌 , 부록

01

분석 개요

분석 배경 및 목적

분석 배경 및 문제 정의

공부시간만으로 학업성취도의 차이를 충분히 설명할 수 있는가 ?

- 학업성취도에 대해서는 흔히 **“공부는 엉덩이 싸움”**이라는 통념이 존재하며 , 선행연구에서도 공부시간은 학업성취와 관련된 주요 요인으로 다뤄져 왔다 .
- 그러나 학업 성취도는 공부시간 뿐 아니라 과제 수행 , 출석 , 꾸준함 , 집중도 , 수면 , 스마트폰 사용 시간 등 **다양한 요인**에 따라 **점수 차이**가 나타날 수 있다 .

선행 연구 방식

- **조사 연구** (이기종 · 곽수란 , 2010) 에서는 **공부시간**을 **학업성취의 핵심**적인 **요인**으로 다룬 바 있다 .
- 다른 연구 (**한국교육문제연구** , 안도희 · 최혜림 , 2012) 에서는 **학업동기** , **가족지원**이 학업성취와 유의한 상관이 있는 것으로 보고된 바 있다 .

문제 정의

- 본 프로젝트에서 검토한 **선행연구**들은 공부시간 , 동기 , 사회적 지지 등 **특정 요인**에 **초점**을 두었다 .
- 실제 **학업 성취도**는 학습 습관 , 심리 상태 , 생활 습관 등과 같은 **여러 학습 · 심리 · 생활 요인**이 함께 **관련**되었을 가능성이 있다 .
- 따라서 개별 관계뿐 아니라 **여러 변수를 동시에 고려**했을 때 **관련성**과 **설명력**을 **확인**하고자 한다 .

학습 습관 , 심리 상태 , 생활 습관과 같은 여러 설명변수를 함께 고려했을때
기말고사 점수를 어느정도 설명할 수 있고 , 상대적으로 관련성이 큰 요인은 무엇인가 ?

분석 목적

기말 고사 점수 관련 요인 , 설명력 확인

1. 학생의 **학습 습관** , **심리 상태** , **생활 습관** , **SNS 사용** 등 여러 변수들이 기말고사 점수와 보이는 관계를 확인한다 .
2. 먼저 각 요인을 개별적으로 살펴본 뒤 , 여러 변수를 동시에 고려했을 때에도 관련성이 유지되는 요인과 모형 전체의 설명력을 확인 .

핵심 질문

Q1. 학습 습관 , 심리 상태 , 생활 습관 변수들은 기말고사 점수와 어떤 관계를 보이는가 ?

Q2. 여러 요인을 동시에 고려했을 때에도 상관분석 결과와 비교해 기말고사 점수와 관련성이 유지되는 요인은 무엇인가 ?

Q3. 최종 회귀모형은 기말고사 점수의 변동을 어느정도 설명하며 , 해석 가능한 범위와 한계는 무엇인가 ?

02

데이터 전처리

데이터 품질 점검

02 데이터 전처리

데이터 소개

출처 : kaggle, 「 Student Academic Performance Prediction 」 , 제작자 : aiexplorer77, License : MIT
설명 : 학업 , 행동 , 심리 , 디지털 활동 등 복합적 요소를 반영하여 실제 학생의 학업 성과를 모사한 합성 데이터셋
(3000 행 , 32 열)

리커트 척도 변수는 응답 간격이 동일하다고 가정하고 회귀에 등간척도로 투입 (참고 문헌)

변수 이름	구분	설명	단위 / 범주	변수 데이터 유형
final_exam_score	종속변수	학생의 기말고사 최종 성적	점수 (0 ~ 100 점)	연속형
study_hours_per_day	독립변수 (학습 습관)	하루 평균 공부 시간	시간 (hours)	연속형
deep_work_sessions	독립변수 (학습 습관)	하루 평균 몰입 학습 (Deep Work) 세션 횟수	회 (count)	연속형
assignment_completion_rate	독립변수 (학습 습관)	과제 완료율 및 제출 비율	퍼센트 (%)	연속형
attendance_percentage	독립변수 (학습 습관)	수업 출석률	퍼센트 (%)	연속형
revision_efficiency	독립변수 (학습 습관)	복습 효율성 점수	리커트 척도 (1 ~ 10)	등간척도
consistency_score	독립변수 (학습 습관)	학습의 꾸준함 및 일관성 점수	리커트 척도 (1 ~ 10)	등간척도
productivity_after_midnight	독립변수 (학습 습관)	심야 시간대 (자정 이후) 학습 생산성 지수	리커트 척도 (1 ~ 10)	등간척도
focus_score	독립변수 (학습 습관)	공부 중 평균 집중도 점수	리커트 척도 (1 ~ 10)	등간척도
procrastination_index	독립변수 (학습 습관)	미루기 습관 지수	리커트 척도 (1 ~ 10)	등간척도
learning_style	독립변수 (학습 습관)	선호하는 학습 스타일	범주 (Visual, Audio, Practical, Reading)	다중 명목형

데이터 소개

변수 이름	구분	설명	단위 / 범주	변수 데이터 유형
social_media_hours	독립변수 (생활 습관)	하루 평균 소셜 미디어 (SNS) 이용 시간	시간 (hours)	연속형
doomscrolling_before_sleep	독립변수 (생활 습관)	취침 전 무의미한 스마트폰 탐색 여부	범주 (Yes / NO)	이진 명목형
notification_distractions	독립변수 (생활 습관)	하루 동안 알림으로 인해 집중이 깨진 횟수	회 (count)	연속형
ai_tool_usage_hours	독립변수 (생활 습관)	하루 평균 AI 도구 (Chat-GPT 등) 활용 시간	시간 (hours)	연속형
gaming_hours	독립변수 (생활 습관)	하루 평균 게임 플레이 시간	시간 (hours)	연속형
sleep_hours	독립변수 (생활 습관)	하루 평균 수면 시간	시간 (hours)	연속형
caffeine_intake	독립변수 (생활 습관)	하루 카페인 섭취량 (음료 / 커피 잔 수)	잔 / 회 (count)	연속형
physical_activity_hours	독립변수 (생활 습관)	신체활동 시간	시간 (hours)	연속형
student_id	단순 식별용	학생 식별 번호 (학생 ID)	범주	다중 명목형
performance_category	final_exam_score(종속) 파생변수	학업 성취도 범주 (성적 등급)	범주 (Low,Medium,High)	다중 명목형

데이터 소개

변수 이름	구분	설명	단위 / 범주	변수 데이터 유형
stress_level	독립변수 (심리 상태)	지각된 스트레스 수준	리커트 척도 (1 ~ 10)	등간척도
motivation_level	독립변수 (심리 상태)	학습 동기 부여 수준	리커트 척도 (1 ~ 10)	등간척도
mental_state	독립변수 (심리 상태)	주관적 정신 건강 / 심리 상태	범주 (Balanced, Focused, Distracted, Burnout)	다중 명목형
burnout_risk	독립변수 (심리 상태)	번아웃 (Burnout) 위험도 지수	리커트 척도 (1 ~ 10)	등간척도
career_goal	독립변수 (심리 상태)	장래 희망 / 진로 목표 분야	범주 (Engineering, Medical, Business, Arts, Research)	다중 명목형
family_support	독립변수 (인구 통계 및 환경)	가족의 지지 및 지원 수준	리커트 척도 (1 ~ 10)	등간척도
financial_stress	독립변수 (인구 통계 및 환경)	경제적 스트레스 수준	리커트 척도 (1 ~ 10)	등간척도
internet_quality	독립변수 (인구 통계 및 환경)	학습 환경의 인터넷 품질 / 상태	리커트 척도 (1 ~ 10)	등간척도
age	독립변수 (인구 통계 및 환경)	학생의 나이	세 (years)	연속형
gender	독립변수 (인구 통계 및 환경)	성별	범주 (Female, Male)	이진 명목형
city_type	독립변수 (인구 통계 및 환경)	거주 도시 유형	범주 (Urban, Semi-Urban, Rural)	다중 명목형

* 인구 통계 및 환경 변수를 제외한 모든 변수는 통제 가능 변수로 구분

데이터 품질 점검

자료형 확인

- 연속형 변수 24 개

  (float(7), int(17))
- 범주형 변수 6 개
  (str → category)

- 불필요 컬럼 2 개 제거
  · student_id :
  단순 넘버링이므로 제거
  · performance_category:
  종속변수의 파생 변수로
  데이터 누수 [1] 위험이 있어
  제거

데이터 중복 확인

- 중복 데이터 없음

결측치 확인

- 결측치 177 개 제거
  (전체 데이터의 5.9%)

결측치 제거 데이터셋과
결측치 미제거 데이터셋을
독립성 검정 후 비교
→ 유의한 차이 없음 확인
후
결측치 제거 (부록 참조)

이상치 확인

- 논리적 이상치 제거
  시간 (hours) 관련 변수 6
개의
  합이 24 시간이 넘는
  데이터 86 개 행 제거 [2]
  (전체 행 대비 5% 미만)

- 논리적 오류가 없는
일반적 이상치는 제거하지
않음

1) 데이터 누수 (leakage): 모델 학습 시 실제 예측 시점에는 알 수 없어야 할 정보가 훈련 데이터에 포함되는 현상 .

2) 여러 시간 변수에 같은 활동이 중복 기록됐을 가능성이 있으나 측정 방식을 알 수 없어 , 합이 24 시간을 넘는 행은 보수적으로 전부 제거함

03

EDA

기술 통계량 · 시각화 · 추론 통계

연속형 변수들

			① 상대편차		왜도		첨도		② 로그변환	③ 이상치	
	mean	50%	rel_diff	rdiff_flag	skew	skew_interpret	kurt	kurt_interpret	log_need	upper_outliers	lower_outliers
age	19.029229	19.0	0.001538	similar	0.016449	symmetric	-1.208714	platykurtic	none	0	0
study_hours_per_day	3.955097	4.0	0.011226	similar	-0.005277	symmetric	-0.253361	platykurtic	none	5	0
deep_work_sessions	3.510047	4.0	0.122488	diff	0.003781	symmetric	-1.239292	platykurtic	none	0	0
assignment_completion_rate	69.948118	70.0	0.000741	similar	-0.008716	symmetric	-1.193485	platykurtic	none	0	0
attendance_percentage	74.498356	74.0	0.006735	similar	0.042604	symmetric	-1.150650	platykurtic	none	0	0
social_media_hours	2.881293	2.9	0.006451	similar	0.117872	symmetric	-0.384140	platykurtic	none	5	0
notification_distractions	61.868834	62.0	0.002116	similar	-0.022163	symmetric	-1.224691	platykurtic	none	0	0
ai_tool_usage_hours	1.530617	1.5	0.020412	similar	0.342289	symmetric	-0.108106	platykurtic	none	19	0
gaming_hours	1.995835	1.9	0.050439	similar	0.389596	symmetric	-0.441728	platykurtic	none	5	0
stress_level	5.550968	6.0	0.074839	similar	-0.024026	symmetric	-1.224717	platykurtic	none	0	0
motivation_level	5.537084	6.0	0.077153	similar	-0.008581	symmetric	-1.207142	platykurtic	none	0	0
focus_score	5.493241	5.0	0.098648	similar	0.030610	symmetric	-1.222737	platykurtic	none	0	0
procrastination_index	5.588966	6.0	0.068506	similar	-0.045481	symmetric	-1.229803	platykurtic	none	0	0
sleep_hours	6.475521	6.5	0.003766	similar	0.041366	symmetric	-0.067042	platykurtic	none	5	9
caffeine_intake	3.507125	3.0	0.169042	diff	0.011081	symmetric	-1.218974	platykurtic	none	0	0
physical_activity_hours	1.043697	1.0	0.043697	similar	0.397344	symmetric	-0.357064	platykurtic	none	8	0
internet_quality	5.530142	6.0	0.078310	similar	-0.032114	symmetric	-1.244126	platykurtic	none	0	0
family_support	5.489953	5.0	0.097991	similar	0.014194	symmetric	-1.188400	platykurtic	none	0	0
financial_stress	5.591524	6.0	0.068079	similar	-0.026117	symmetric	-1.187235	platykurtic	none	0	0
productivity_after_midnight	5.548411	6.0	0.075265	similar	-0.017470	symmetric	-1.216371	platykurtic	none	0	0
revision_efficiency	5.443917	5.0	0.088783	similar	0.017993	symmetric	-1.251204	platykurtic	none	0	0
burnout_risk	5.519182	6.0	0.080136	similar	-0.021028	symmetric	-1.197957	platykurtic	none	0	0
consistency_score	5.543296	6.0	0.076117	similar	-0.028150	symmetric	-1.206622	platykurtic	none	0	0
final_exam_score	54.759956	55.0	0.004364	similar	0.061016	symmetric	-0.238795	platykurtic	none	0	5

- **① 대부분 연속형 변수는 평균과 중앙값이 유사**
- deep_work_sessions(0.12), caffeine_intake(0.17) 만 약간의 상대편차
- **② 왜도 · 첨도 : | 왜도 | < 0.5(대칭), 첨도 < 0(완만)**
  → 모든 연속형 변수 로그변환 불필요
- **③ 이상치는 모두 1% 미만 → 경계값 대체 여부는 모형 비교 후 결정**

명목형 변수들

- 명목형 변수 **6 개** 모두 **특정 범주에 쏠려** 있지 않다 . (최대 / 최소 비율 차이가 5% 이내→더미 코딩 시 희소 범주 문제가 없는 수준)

* 모든 변수가 균등한 분포 → 합성 데이터이기 때문으로 추정

성별

gender	count
Female	1388 (50.7%)
Male	1349 (49.3%)

도시 타입

City_type	count
Rural	927 (33.9%)
Semi-Urban	921 (33.6%)
Urban	889 (32.5%)

심리 상태

Mental_state	count
Balanced	660 (24.1%)
Burnout	691 (25.3%)
Distracted	718 (26.2%)
Focused	668 (24.4%)

학습 방식

Learning_style	count
Audio	661 (24.2%)
Practical	696 (25.4%)
Reading	662 (24.2%)
Visual	718 (26.2%)

커리어 목표

Career_goal	count
Arts	582 (21.3%)
Business	534 (19.5%)
Engineering	539 (19.7%)
Medical	575 (21.0%)
Research	507 (18.5%)

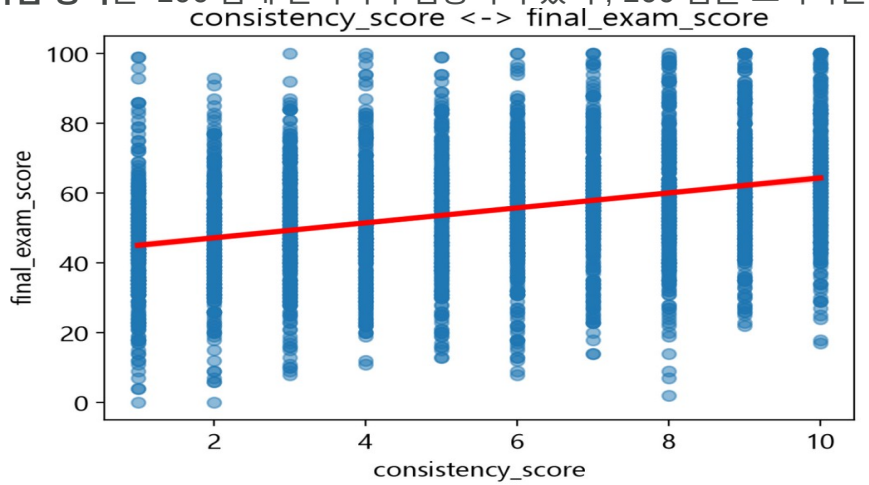
자기 전 무한 스크롤 여부

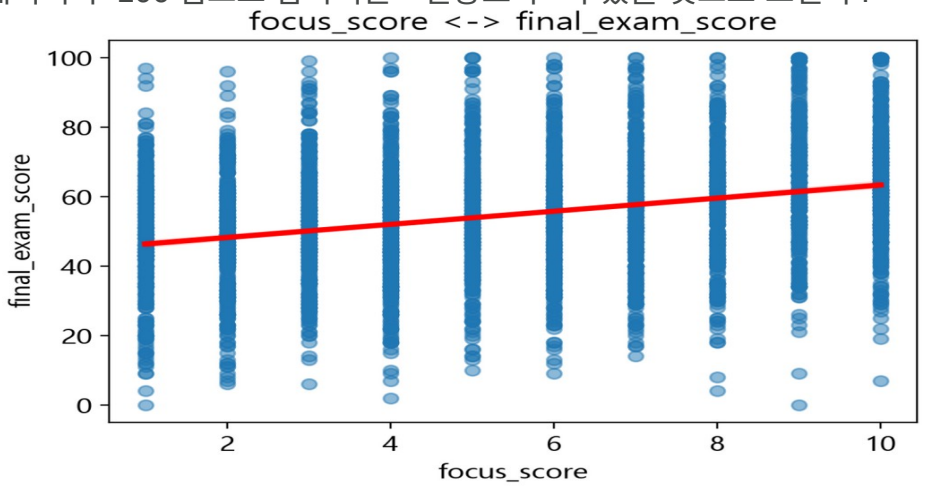
doomscrolling_before_sleep	count
0(No)	1380 (50.4%)
1(Yes)	1357 (49.6%)

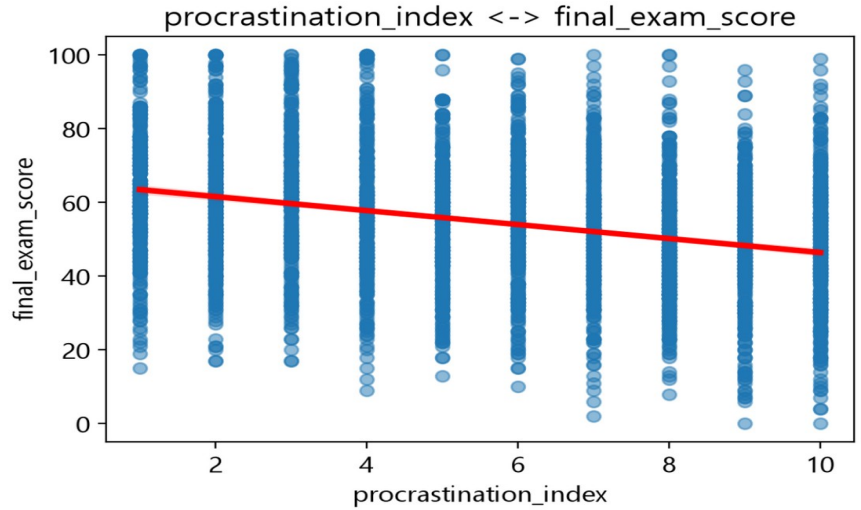
천장효과 : 어떤 변수의 값이 일정 수준에 도달하면 , 원인 (투입량 , 노력 등) 을 아무리 늘려도 결과 (효과 , 성과 등) 가 더 이상 증가하지 않고 한계에 부딪히는 현상

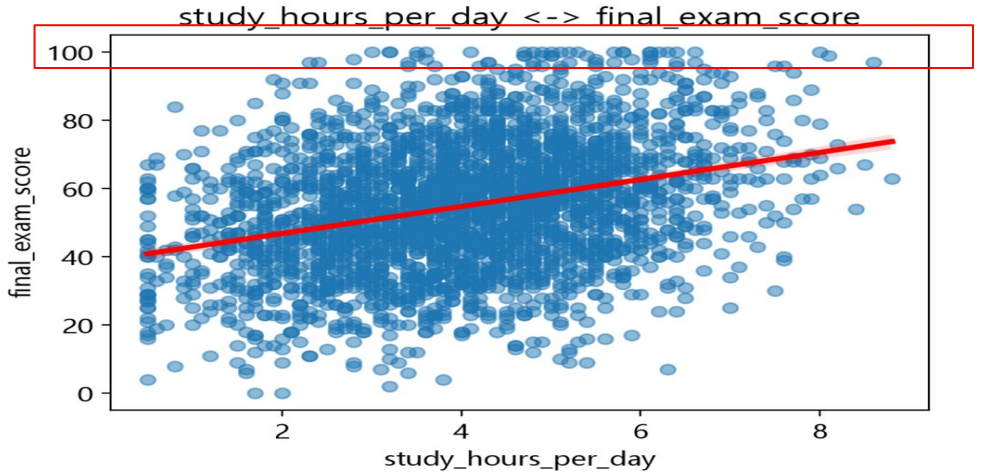
연속형 변수 - 성적과의 관계

- 연속형 변수 중 consistency_score(**꾸준함**), focus_score(**집중도**), study_hours_per_day(**공부시간**) 는 기말시험 점수 **상승** 경향 .
- procrastination_index(**미루기 지수**) 는 **하락** 경향이 관찰되었다 .
- 다만 **기말시험 성적**은 100 점에 관측치가 집중되어 있어 , 100 점을 초과하는 실제 데이터가 100 점으로 압축되는 ' 천장효과 ' 가 있을 것으로 보인다 .





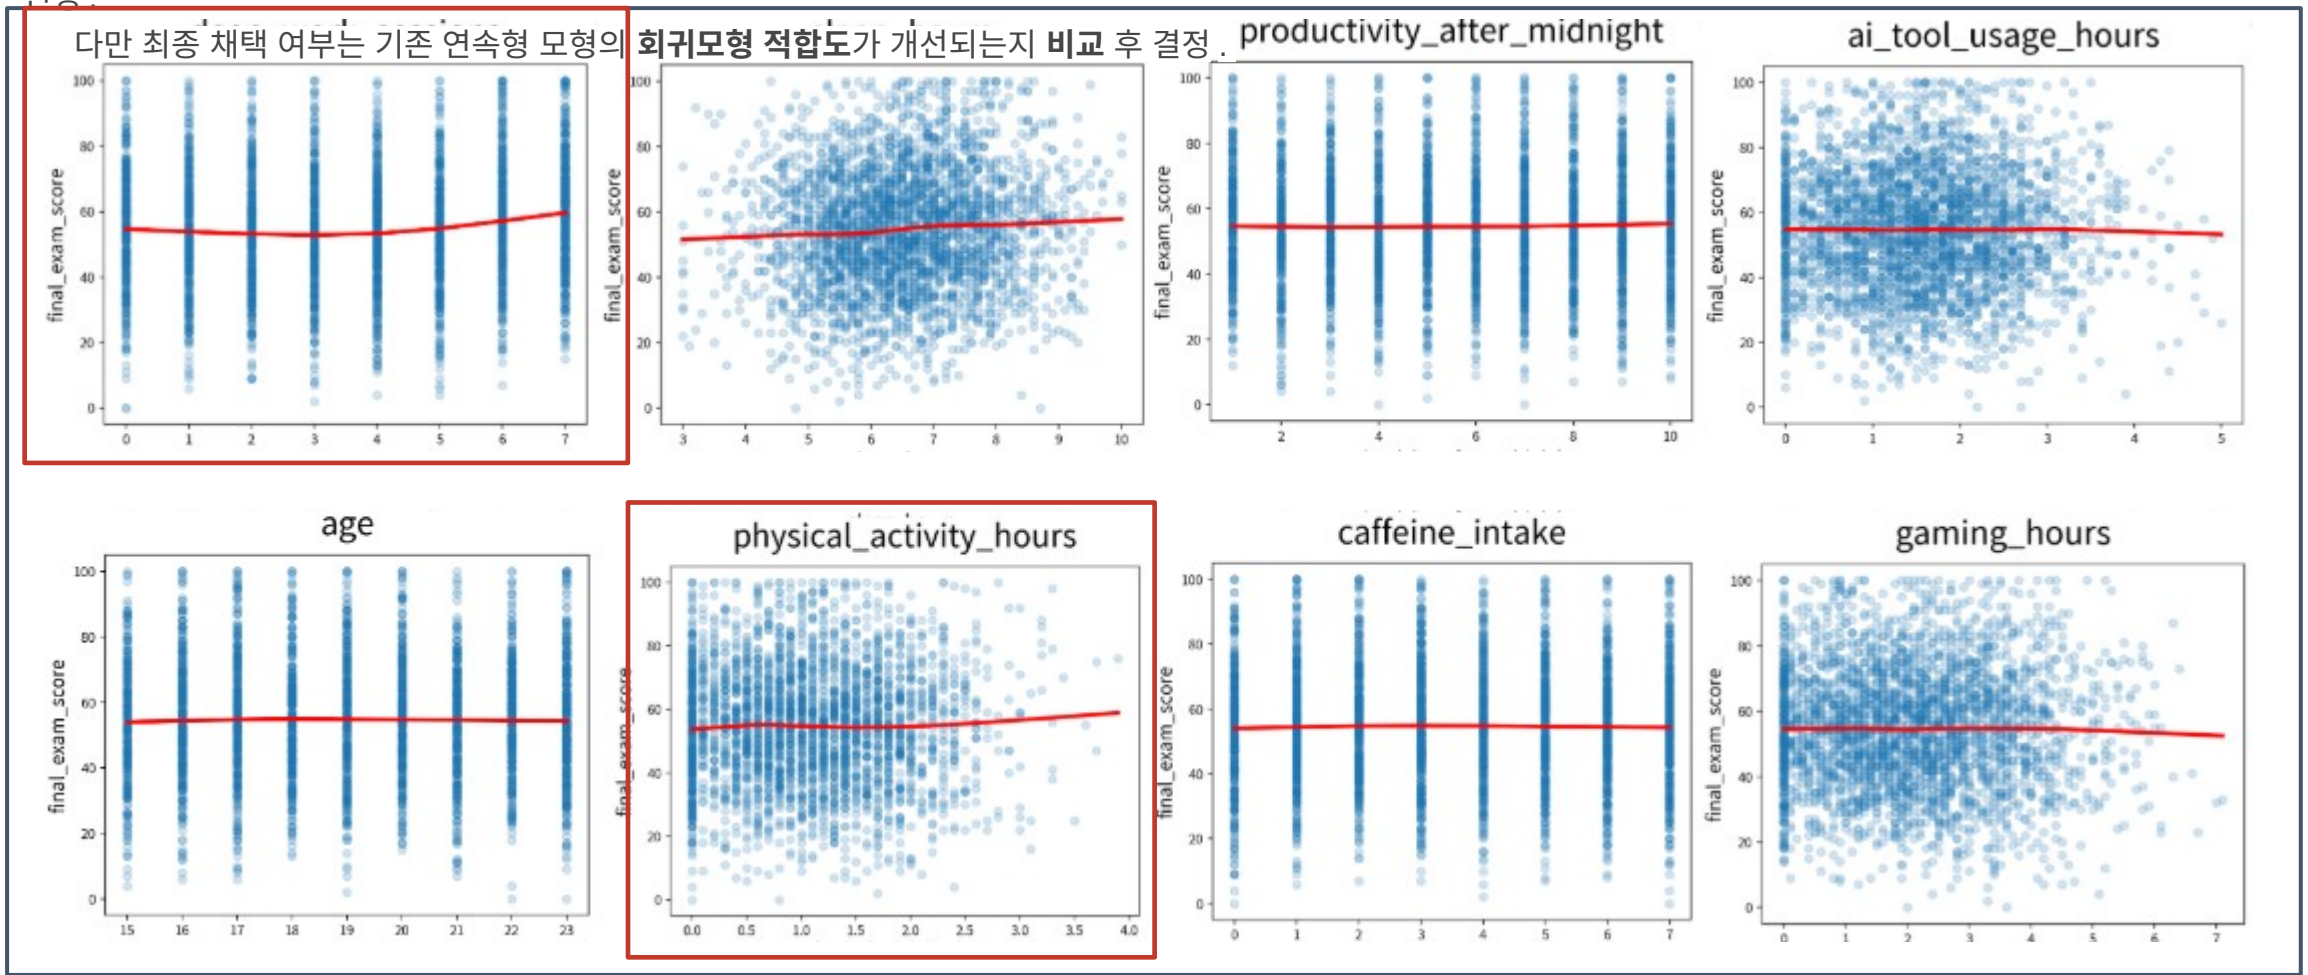




연속형 변수 - 선형이 아닌 경우 대안 검토

1. **deep_work_sessions** 는 초반에는 거의 변화를 보이지 않다가 , 특정 구간에서 기말 고사 성적이 높아지는 **임계점 패턴**이 발견 .
   이는 단순 **선형 가정** (1 회 증가시 점수도 일정하게 변화) 으로 **설명되지 않기에** , 특정 구간 별 그룹을 서로 묶어 **범주형**으로 종속변수가 **설명되는지** 확인 필요 .
2. **physical_activity_hours** 는 **0** 시간에 관측치가 별도 군집을 이루어 ' **0 시간'** (신체활동 없음) 과 ' **0 시간 초과'** (신체활동 있음) 의 두 집단으로 탐색적 분석을 진행 .

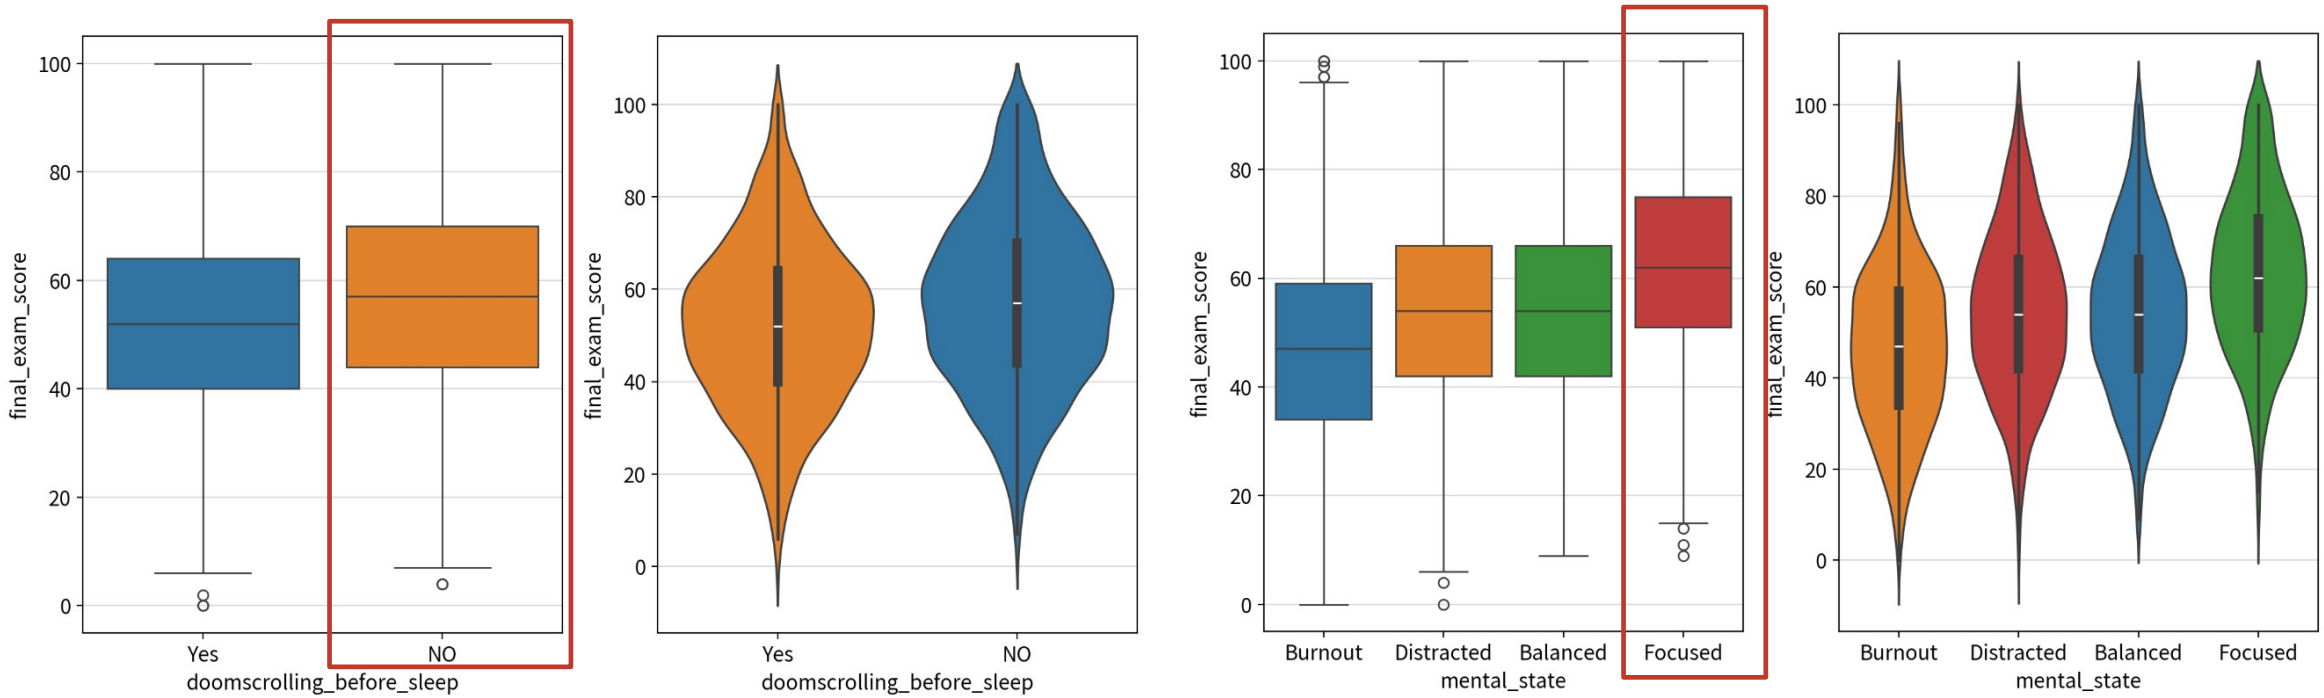
다만 최종 채택 여부는 기존 연속형 모형의 **회귀모형 적합도**가 개선되는지 **비교** 후 결정 .



명목형 변수

- **자기 전 , 무한 스크롤**을 '하지 않는 그룹'과 **심리상태** ' Focused' 인 그룹은 중앙값이 **다소 높게** 나타났다 .

- 시각적 차이가 **우연**인지 , 통계적으로 **유의미**한지 **검증**하기 위해 각각 T 검정과 ANOVA 분석 필요 .



상관분석 (기말 시험 점수 × 연속형 독립 변수)

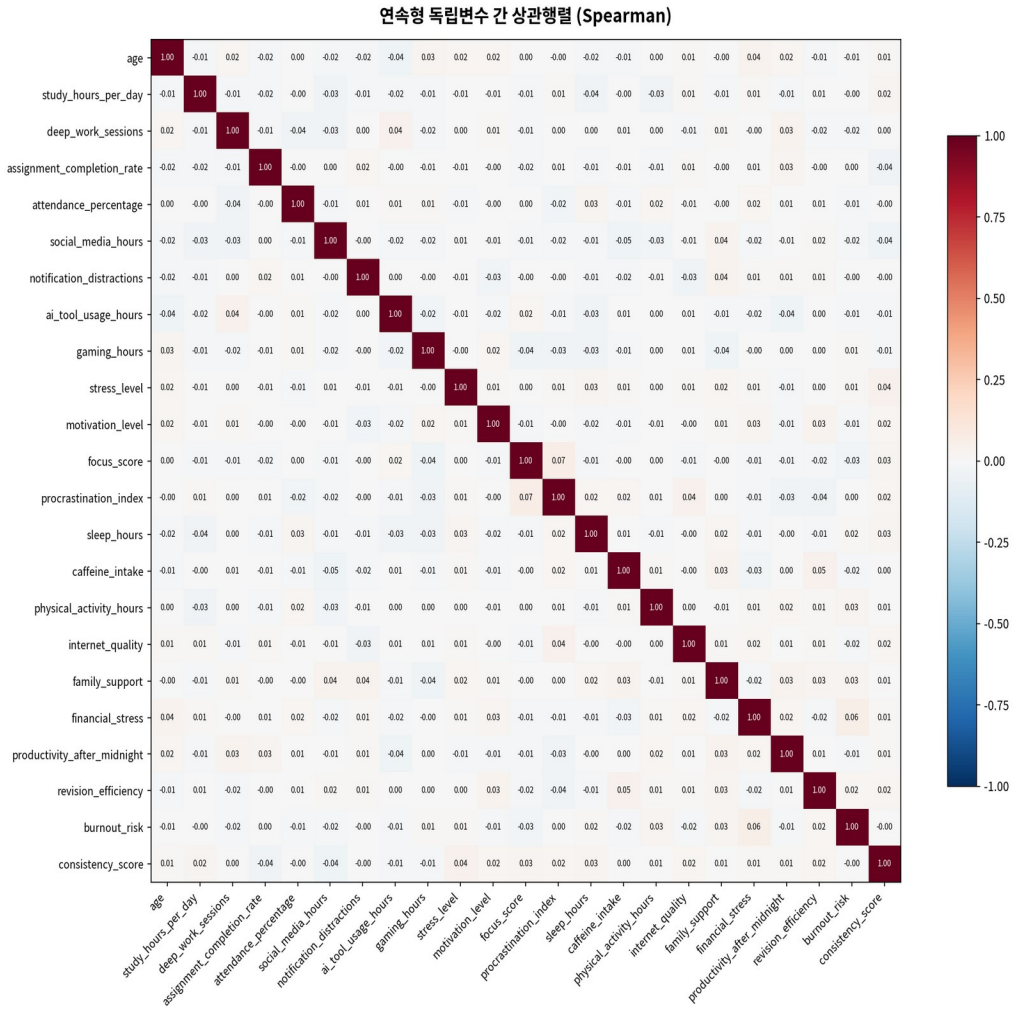
종속변수 (final_exam_score) 가 비정규성 → Spearman 기법 사용

- **꾸준함** , **하루 공부시간**은 유의미한 **양의 상관** (ρ≥ 0.3) 을 보였으며 , 반대로 **미루기 지수**는 가장 강한 **음의 상관** (ρ = -0.29) 이 나타났다 .
- 단일 변수와의 **최대 상관계수**가 **0.33**(중간 수준) 에 불과해 , **개별 변수**만으로 기말시험 점수 (종속변수) **설명에 한계**가 있다 .
- 따라서 초기에 **잠재적인 유효 변수 누락을 방지**하고자 , 전통적 기준 (**|ρ |≥0.3**) 으로 후보를 선정하는 **대신** **|ρ |≥0.1** 인 변수들까지도 회귀분석 **후보군으로 채택** .
- 또한 **|ρ|<0.1** 이더라도 **p-value < 0.05** 인 경우 유의한 것으로 보고 , **후보군에 포함** .

변수명	한글명	분석 방법	P-value	상관계수 (ρ)	방향	강도 (PDF)	채택 여부
consistency_score	꾸준함 점수	Spearman	<0.001	0.323	양 (+)	중간	✅ 채택
study_hours_per_day	하루 공부시간	Spearman	<0.001	0.306	양 (+)	중간	✅ 채택
focus_score	집중도 점수	Spearman	<0.001	0.285	양 (+)	약함	✅ 채택
procrastination_index	미루기 지수	Spearman	<0.001	-0.277	음 (-)	약함	✅ 채택
burnout_risk	번아웃 위험	Spearman	<0.001	-0.252	음 (-)	약함	✅ 채택
revision_efficiency	복습 효율	Spearman	<0.001	0.216	양 (+)	약함	✅ 채택
motivation_level	학습동기 수준	Spearman	<0.001	0.201	양 (+)	약함	✅ 채택
social_media_hours	SNS 사용시간	Spearman	<0.001	-0.182	음 (-)	약함	✅ 채택
stress_level	스트레스 수준	Spearman	<0.001	-0.178	음 (-)	약함	✅ 채택
attendance_percentage	출석률	Spearman	<0.001	0.173	양 (+)	약함	✅ 채택
assignment_completion_rate	과제 완료율	Spearman	<0.001	0.152	양 (+)	약함	✅ 채택
financial_stress	경제적 스트레스	Spearman	<0.001	-0.128	음 (-)	약함	✅ 채택
deep_work_sessions	집중학습 세션수	Spearman	<0.001	0.083	양 (+)	미미함	✅ 채택
sleep_hours	수면시간	Spearman	<0.001	0.078	양 (+)	미미함	✅ 채택
notification_distractions	알림 방해 정도	Spearman	0.218	-0.024	음 (-)	무시가능	—
productivity_after_midnight	자정이후 생산성	Spearman	0.362	0.017	양 (+)	무시가능	—
internet_quality	인터넷 품질	Spearman	0.575	-0.011	음 (-)	무시가능	—
age	나이	Spearman	0.728	0.007	양 (+)	무시가능	—
gaming_hours	게임 사용시간	Spearman	0.764	-0.006	음 (-)	무시가능	—
family_support	가족 지원	Spearman	0.784	-0.005	음 (-)	무시가능	—
physical_activity_hours	신체활동 시간	Spearman	0.820	-0.004	양 (+)	무시가능	—
ai_tool_usage_hours	AI 도구 사용시간	Spearman	0.978	0.001	양 (+)	무시가능	—

상관분석 표 (n=2,737 기준)

상관분석 (연속형 × 연속형 독립 변수 간)



연속형 독립변수 간 상관분석 → |ρ| 상위 10 쌍 (전체 253 쌍)

변수 X	변수 Y	상관계수 (Spearman)	p-value	유의(p<.05)
focus_score	procrastination_index	0.067	0.000	O
financial_stress	burnout_risk	0.058	0.003	O
caffeine_intake	revision_efficiency	0.045	0.018	O
social_media_hours	caffeine_intake	-0.045	0.018	O
ai_tool_usage_hours	productivity_after_midnight	-0.044	0.020	O
gaming_hours	focus_score	-0.043	0.024	O
age	ai_tool_usage_hours	-0.041	0.030	O
social_media_hours	consistency_score	-0.041	0.031	O
gaming_hours	family_support	-0.041	0.031	O
deep_work_sessions	ai_tool_usage_hours	0.041	0.032	O

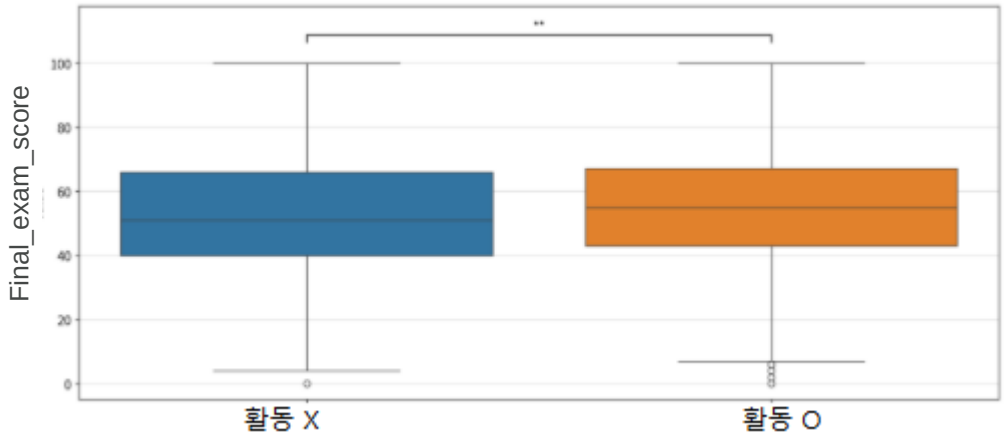
p 값은 통계적으로 유의하다고 나왔으나 , 효과크기는 무의미한 수준

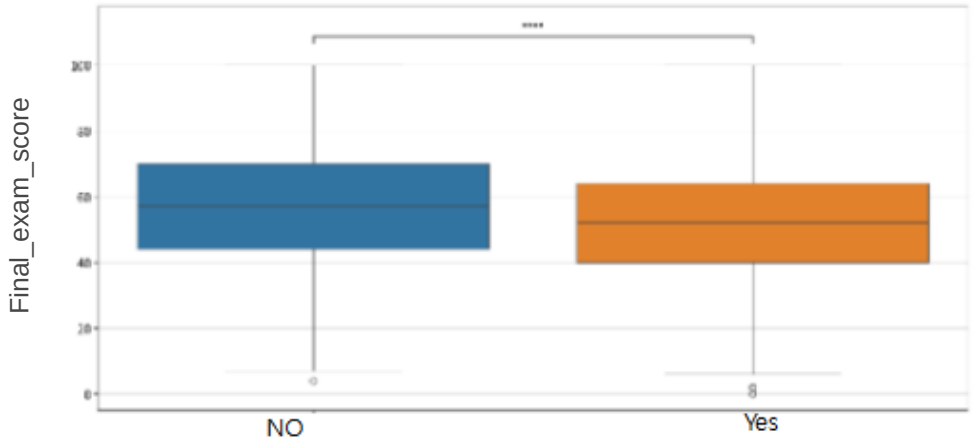
독립변수 간 최대 **|ρ| = 0.067**
→ 강한 상관을 보이는 변수쌍 미확인 . (연속형 최대 VIF : 1.03)
즉 , 모든 독립변수가 사실상 서로 무상관 .

* 실제 교육 데이터라면 개념적으로 관련될 수 있는 집중도 , 동기 , 꾸준함 , 스트레스 , 번아웃 같은
학습 - 심리 변수들도 거의 독립적으로 나타난다 .
- 이부분은 데이터 생성 시 , 각 변수가 독립적으로 생성되었을 가능성을 시사한다 .

이진 범주형 집단 비교

- **두 변수 (physical_activity_hours, doomscrolling_before_sleep)** 모두 **정규성 불만족**하여 , **Mann-Whitney U 검정** 방식으로 검정 진행 .
- **physical_activity_hours**, **doomscrolling_before_sleep** 설명변수가 **집단 간 차이**가 통계적으로 **유의미**하게 나타났다 . (회귀분석의 설명변수 후보)





1. physical_activity_hours	결과
검정 방법	**Mann-Whitney U test**
U 통계량	343268.5
p-value (양측)	0.0061 (p < 0.05)
방향 (단측)	활동 O > 활동 X (p=0.003)
결론	신체 활동 시간에 따른 기말 점수 차이는 통계적으로 유의하며 , 활동하는 쪽이 더 높게 나타났다 .

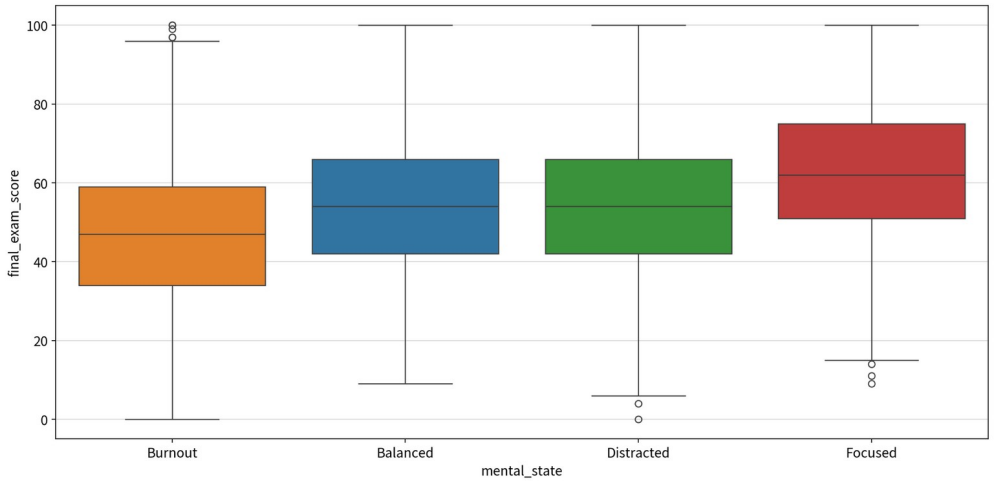
2. doomscrolling_before_sleep	결과
검정 방법	**Mann-Whitney U test**
U 통계량	1080968.5
p-value (양측)	p<0.001
방향 (단측)	취침전 스마트폰 사용함 < 사용 안함 (p<0.001)
결론	‘ 취침 전 스마트폰을 사용하지 않는 집단’의 기말고사 점수가 ‘취침 전 스마트폰을 사용하는 집단’보다 통계적으로 유의하게 높게 나타났다 .

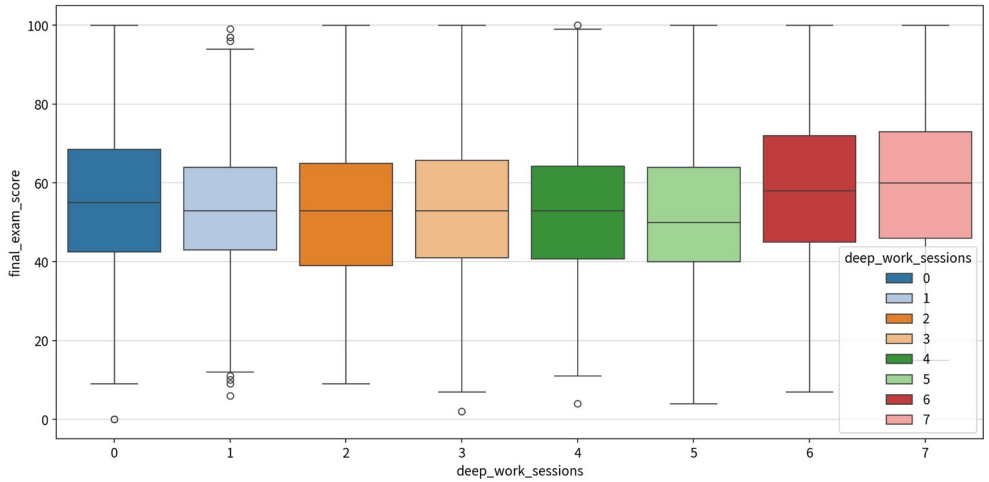
***physical_activity_hours 컬럼은 연속형이지만 , 비선형 탐색을 위해 집단 명목형으로 가정 후 이진 범주형 집단 비교 진행 .**

* 가정 검정 결과는 부록 첨부

3 집단 이상 명목형 독립변수 간

- city_type 을 제외한 변수가 **등분산성을 충족**해 **일원분산분석 검정** 방법으로 진행 . (city_type 은 등분산 위배 → Welch 검정 , 결과 동일하게 비유의)
- mental_state(**심리상태**), deep_work_sessions(**하루 집중한 횟수**) 두 변수는 **집단 간 차이**가 통계적으로 **유의미** (p<0.001) 하게 나타났다 . (회귀분석의 설명변수 후보)
- 다만 **3 집단 이상**이기에 , **어떤 그룹**이 **얼마나 차이나는지**를 확인하고자 **사후검정** 진행 .





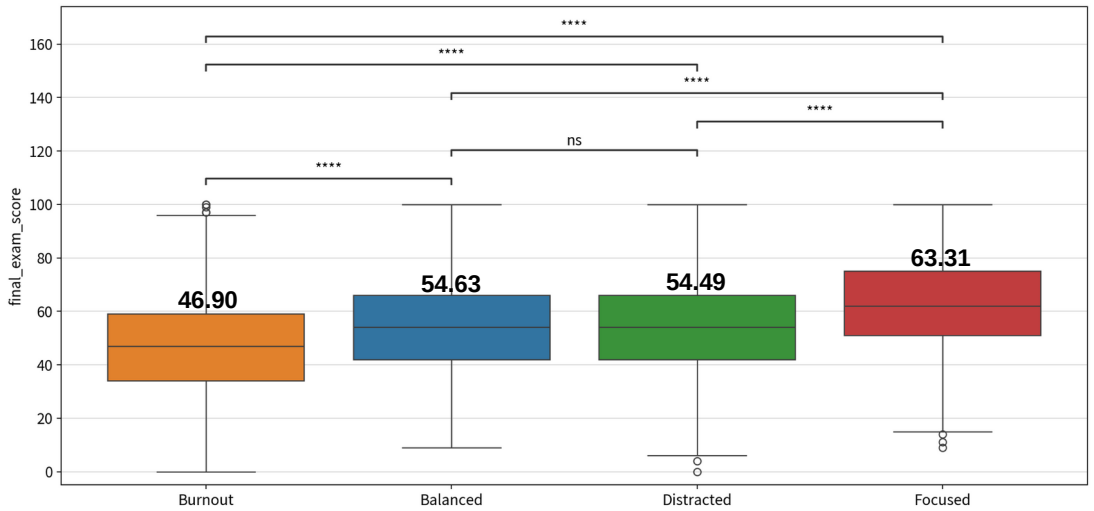
변수	검정	F	ddof1	ddof2	p-value	효과크기 η^2 (np2)
mental_state	**One-way ANOVA**	**97.254**	**3**	**2733**	**< 0.001**	**0.096 (Medium)**
deep_work_sessions	**One-way ANOVA**	**9.728**	**7**	**2729**	**< 0.001**	**0.024 (Small)**
city_type	Welch ANOVA	2.892	2	1822.5	0.056	0.002 (Negligible)
learning_style	One-way ANOVA	0.601	3	2733	0.614	0.001 (Negligible)
career_goal	One-way ANOVA	0.603	4	2732	0.661	0.001 (Negligible)

***deep_work_sessions 컬럼은 0~7 회 연속형이지만 , 비선형 탐색을 위해 집단 명목형으로 가정 후 일원분산분석 검정 진행 .**

* 가정 검정 결과는 부록 첨부

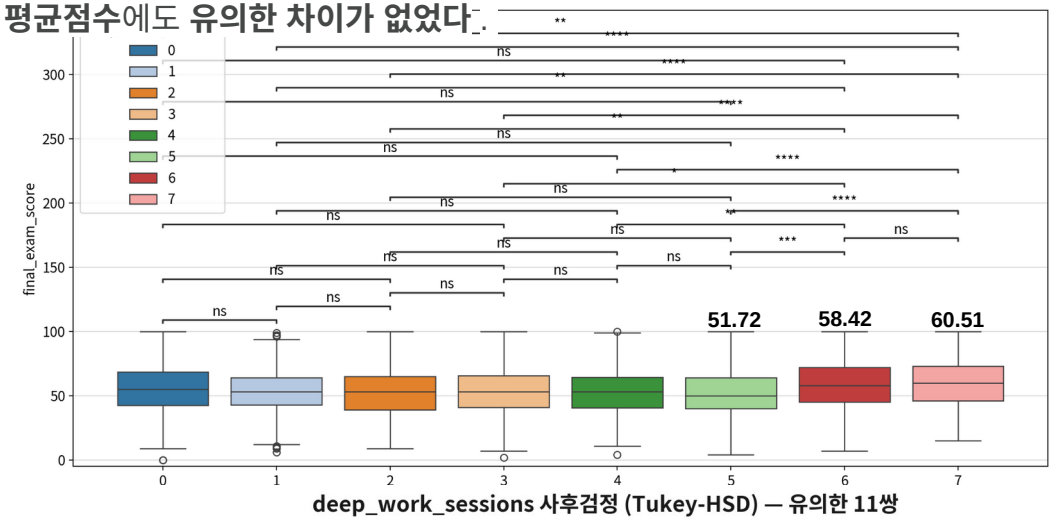
사후검정

1. **mental_state** 변수 내 그룹 Balanced 와 Distracted 그룹 간 차이는 **유의하지 않았다** (p=0.999).
   반면 Focused 와 Burnout 그룹은 각각 나머지 그룹들과 **유의한 차이**를 보였으며 , 평균 점수는 Focused 가 가장 높고 Burnout 이 가장 낮았다 .
2. **deep_work_sessions** 변수는 **6 회 ·7 회 그룹**의 **평균 점수**가 **0~5 회 그룹**보다 상대적으로 **높게 나타났다 (0 회 ↔ 6 회 쌍만 비유의 , p=0.23)**,
   반면 **6 회와 7 회 집단 사이의 평균 점수에 차이가 없었으며** , **0~5 회** 각 **집단 사이 평균점수**에도 **유의한 차이가 없었다**.



mental_state 사후검정 (Tukey-HSD) — 집단 간 쌍별 비교

비교 쌍	평균 A → B	차이	p (Tukey-HSD)	효과크기 |Hedges g|	유의
Balanced ↔ Burnout	54.63 → 46.90	+7.74	< 0.001	0.436 (Small)	O
Balanced ↔ Distracted	54.63 → 54.49	+0.15	0.999	0.008 (Negligible)	X
Balanced ↔ Focused	54.63 → 63.31	−8.68	< 0.001	0.492 (Small)	O
Burnout ↔ Distracted	46.90 → 54.49	−7.59	< 0.001	0.426 (Small)	O
Burnout ↔ Focused	46.90 → 63.31	−16.42	< 0.001	0.919 (Large)	O
Distracted ↔ Focused	54.49 → 63.31	−8.83	< 0.001	0.498 (Small)	O



deep_work_sessions 사후검정 (Tukey-HSD) — 유의한 11쌍

비교 쌍	평균 A → B	차이	p (Tukey-HSD)	효과크기 |Hedges g|
0회 ↔ 7회	54.92 → 60.51	−5.59	0.002	0.299 (Small)
1회 ↔ 6회	53.35 → 58.42	−5.07	0.008	0.277 (Small)
1회 ↔ 7회	53.35 → 60.51	−7.16	< 0.001	0.397 (Small)
2회 ↔ 6회	52.95 → 58.42	−5.46	0.004	0.291 (Small)
2회 ↔ 7회	52.95 → 60.51	−7.56	< 0.001	0.409 (Small)
3회 ↔ 6회	53.53 → 58.42	−4.89	0.016	0.258 (Small)
3회 ↔ 7회	53.53 → 60.51	−6.98	< 0.001	0.374 (Small)
4회 ↔ 6회	52.69 → 58.42	−5.73	0.001	0.308 (Small)
4회 ↔ 7회	52.69 → 60.51	−7.82	< 0.001	0.426 (Small)
5회 ↔ 6회	51.72 → 58.42	−6.69	< 0.001	0.359 (Small)
5회 ↔ 7회	51.72 → 60.51	−8.79	< 0.001	0.478 (Small)

※ 전체 28쌍 중 유의 쌍만 표시. 나머지 17쌍(0~5회 그룹 간, 6↔7회)은 모두 비유의(p > .05).

최종 설명변수 후보 List

* 해당 표는 **deep_work_sessions** 와 **physical_activity_hours** 를 그룹화하여 **이진 명목형**으로 분석한 결과 .

변수명	한글명	분석 방법	가정점검	P-value	효과크기 (ρ, np2)	강도 (PDF)	비대칭신호	로그변환	공선성신호	채택 여부
consistency_score	꾸준함 점수	Spearman	정규성 위배	<0.001	0.323	중간	대칭	불필요	X	✅ 채택
study_hours_per_day	하루 공부시간	Spearman	정규성 위배	<0.001	0.306	중간	대칭	불필요	X	✅ 채택
doomscrolling_before_sleep	취침 전 스마트폰 사용	Mann-Whitney U	정규성 위배	<0.001	미제공	미제공	해당없음	해당없음	X	✅ 채택
mental_state	정신 상태	One way_anova	등분산성 충족	<0.001	0.096	중간	해당없음	해당없음	X	✅ 채택
focus_score	집중도 점수	Spearman	정규성 위배	<0.001	0.285	약함	대칭	불필요	X	✅ 채택
procrastination_index	미루기 지수	Spearman	정규성 위배	<0.001	-0.277	약함	대칭	불필요	X	✅ 채택
burnout_risk	번아웃 위험	Spearman	정규성 위배	<0.001	-0.252	약함	대칭	불필요	X	✅ 채택
revision_efficiency	복습 효율	Spearman	정규성 위배	<0.001	0.216	약함	대칭	불필요	X	✅ 채택
motivation_level	학습동기 수준	Spearman	정규성 위배	<0.001	0.201	약함	대칭	불필요	X	✅ 채택
social_media_hours	SNS 사용시간	Spearman	정규성 위배	<0.001	-0.182	약함	대칭	불필요	X	✅ 채택
stress_level	스트레스 수준	Spearman	정규성 위배	<0.001	-0.178	약함	대칭	불필요	X	✅ 채택
attendance_percentage	출석률	Spearman	정규성 위배	<0.001	0.173	약함	대칭	불필요	X	✅ 채택
assignment_completion_rate	과제 완료율	Spearman	정규성 위배	<0.001	0.152	약함	대칭	불필요	X	✅ 채택
financial_stress	경제적 스트레스	Spearman	정규성 위배	<0.001	-0.128	약함	대칭	불필요	X	✅ 채택
sleep_hours	수면시간	Spearman	정규성 위배	<0.001	0.078	미미함	대칭	불필요	X	✅ 채택
deep_work_sessions	집중학습 세션수	Mann-Whitney U	정규성 위배	<0.001	미제공	미미함	대칭	불필요	X	✅ 채택
physical_activity_hours	신체활동 시간	Mann-Whitney U	정규성 위배	0.006	미제공	미미함	대칭	불필요	X	🟡 후보
notification_distractions	알림 방해 정도	Spearman	정규성 위배	0.218	-0.024	무시 가능	대칭	불필요	X	—
productivity_after_midnight	자정이후 생산성	Spearman	정규성 위배	0.362	0.017	무시 가능	대칭	불필요	X	—
internet_quality	인터넷 품질	Spearman	정규성 위배	0.575	-0.011	무시 가능	대칭	불필요	X	—
age	나이	Spearman	정규성 위배	0.728	0.007	무시 가능	대칭	불필요	X	—
gaming_hours	게임 사용시간	Spearman	정규성 위배	0.764	-0.006	무시 가능	대칭	불필요	X	—
family_support	가족 지원	Spearman	정규성 위배	0.784	-0.005	무시 가능	대칭	불필요	X	—
ai_tool_usage_hours	AI 도구 사용시간	Spearman	정규성 위배	0.978	0.001	무시 가능	대칭	불필요	X	—
caffeine_intake	카페인 섭취량	Spearman	정규성 위배	0.999	0.000	무시 가능	대칭	불필요	X	—
city_type	거주지 유형	Welch anova	등분산성 위배	0.056	0.002	무시 가능	해당없음	해당없음	X	—
learning_style	학습 스타일	One way_anova	등분산성 충족	0.614	0.001	무시 가능	해당없음	해당없음	X	—
career_goal	커리어 목표	One way_anova	등분산성 충족	0.661	0.001	무시 가능	해당없음	해당없음	X	—
gender	성별	Mann-Whitney U	정규성 위배	0.356	미제공	미제공	해당없음	해당없음	X	—

(n=2,737 기준)

04

회귀분석 및 평가

다중선형회귀 · 모델 선정 · 가정 검정

다중 선형 회귀를 진행하는 이유

상관분석 & 집단 차이 검정은 각 **설명변수**를 **개별로 확인**한 결과이다 .

그러나 **개별 분석만**으로는 여러 설명변수를 **함께 사용**했을 때 점수변동을 전체적으로 **얼마나 설명**할 수 있는지 ,
각 변수가 다른 **조건**을 같이 고려한 뒤에도 **유지**되는지를 알 수 없다 .

따라서 개별적으로 확인한 관계들을 **하나의 모형**에 투입해 **모형의 설명력**과
조건이 같은 경우 **관련성을 확인**하고 적합도와 간결성을 **비교**해보기 위해 **다중선형 회귀**를 진행 .

	개별 분석	다중 회귀
1	설명변수 하나씩 점수와 관계 · 집단 차이 확인	여러 설명변수를 하나의 모형에서 함께 고려
2	변수별 관계의 방향과 크기는 알 수 있음	다른 설명변수를 고려한 조건부 회귀계수 확인 (단 , 본 데이터는 변수 간 상관이 거의 없어 조건부 계수와 단순 상관이 거의 같게 나옴 → p.33 참조)
3	여러 변수가 점수를 함께 얼마나 설명하는지는 알 수 없음	R^2· 수정 R^2 로 모형 전체 설명력 확인
4	변수 조합에 따른 모형 차이를 비교할 수 없음	AIC·BIC·RMSE·MAE 로 모형을 비교하고 선정

회귀 모델 전처리 · 설계 근거

모델 적용 모델 미적용

범주형 더미변환	각 모델에 적합한 명목형 변수를 더미변수로 변환
로그 변환	적용하지 않음 (기술통계량 확인 시 모든 변수 대칭)
이상치	1. 일일 시간 컬럼 합이 24 시간 초과인 행 삭제 2. IQR 기준 통계적 이상치 → 경계값 대체 비교 . 결과 회귀 모델 성능 차이 없어 , 최종 모델 미적용
다중공선성	연속형 변수들의 최대 VIF = 1.03 으로 기준값 10 미만이기에 미진행
스케일링	- 원본 해석 용이성을 위해 미진행 (기존 단위 유지) - 변수 간 상대적 중요도는 회귀 결과로 산출된 표준화 계수를 통해 비교

전처리 단계별 모델 비교

- 모델 선정 시 **아래 전처리 단계**를 기준으로 같은 모델 성능을 비교하였다 .
  > 비교 결과 : 두 단계의 모든 지표 차이가 0.01% 미만 → 이상치 대체의 효과 없음 .**<**
- 따라서 모든 모델이 불필요한 변환을 하지 않은 **0. 기준선** 전처리 단계 모형을 기준으로 채택되었다 .

단계	변수 수	R^2 (모델)	adj.R^2	AIC	BIC	RMSE	MAE
0. 기준선	17	0.8101	0.8089	19267.7	19374.2	8.1202	6.4823
1. 이상치대체	17	0.8101	0.8089	19268.1	19374.6	8.1207	6.4830

변수 표현 방식 별 회귀 모형 설계

전처리 단계별 비교를 통해 기준선 전처리를 확정한 뒤 , **EDA** 에서 **단순 직선**으로 **설명하기 어려운** 패턴이 관찰된 **변수**의 회귀 **표현 방식**을 검토했다 . 다른 설명변수와 분석 표본은 **동일하게 유지**하고 , **deep_work_sessions** 와 **physical_activity_hours** 만 원래 **수치형** 또는 **그룹형 더미변수**로 다르게 표현한 대안 모형을 구성하였다 .

[회귀 모형 분류]

회귀 방식 1. 연속형 (기본 모형)

회귀 방식 2. 연속 + 그룹형 (두 컬럼 중 각각 1 컬럼 씩)

회귀 방식 3. 그룹형 (두 컬럼 모두) 이 3 가지 방법으로 회귀를 진행한다 .

변수	deep_work_sessions	physical_activity_hours
① 기본 모델 (회귀 방식 1)	연속형 (0~7 회의 횟수)	연속형 (시간)
②physical_activity_hours 그룹화 (회귀 방식 2)	연속형 (0~7 회의 횟수)	0 시간 / 0 시간 초과 그룹 더미
③ deep_work_sessions 그룹화 (회귀 방식 2)	0~5 회 /6~7 회 그룹 더미 변수	연속형 (시간)
④ 운동 & 딥세션 그룹화 (회귀 방식 3)	0~5 회 /6~7 회 그룹 더미 변수	0 시간 / 0 시간 초과 그룹 더미

변수명	EDA 결과
deep_work_sessions	1. 상관분석 결과 , 효과크기 작음 (ρ=0.089) 2. ANOVA 결과 , 유의 (p<0.001)
physical_activity_hours	1. 연속형 결과 : 비유의 (p=0.820) 2. 0 시간 여부 이분화 : 유의 (p=0.006) → 그룹형 검토 대상

모델 선정 (모형 간 비교)

모델 선정 기준

- **adj. R^2** : 설명력이 높을수록 우수
- **AIC / BIC** : 적합도 대비 간결성
- **RMSE** : 낮을수록 오차가 적음

* 모형 설명력과 오차가 사실상 동일할 경우 AIC·BIC 와 변수 수를 고려해 더 간결한 모형을 선택 .

- **3 번 모형**을 최종 모형으로 선정 .

— 3,4 번 모델이 adj.R^2 가 1,2 번 모델에 비해 높았으며 , AIC/BIC, RMSE, MAE 는 더 낮은 수치이기에 후보군으로 선정 .

3 번은 adj R^2 와 예측 오차 (RMSE) 가 거의 차이가 없으며 BIC 가 가장 낮음 . 해석 간결성 (변수 17 개) 이 좋음 .

모델	변수 수	R^2 (모델)	adj.R^2	AIC	BIC	R^2 (원본)	RMSE	MAE
① 기본 모델 (회귀 방식 1) (EDA 기준 유의한 변수들)	17	0.8101	0.8089	19267.7	19374.2	0.8101	8.1202	6.4823
②physical_activity_hours 그룹화 (회귀 방식 2)	18	0.8107	0.8094	19261.5	19373.9	0.8107	8.1080	6.4684
③ deep_work_sessions 그룹화 (회귀 방식 2)	17	0.8186	0.8175	19142.5	19249.0	0.8186	7.9365	6.3463
④ 운동 & 딥세션 그룹화 (회귀 방식 3)	18	0.8189	0.8177	19139.8	19252.1	0.8189	7.9295	6.3362

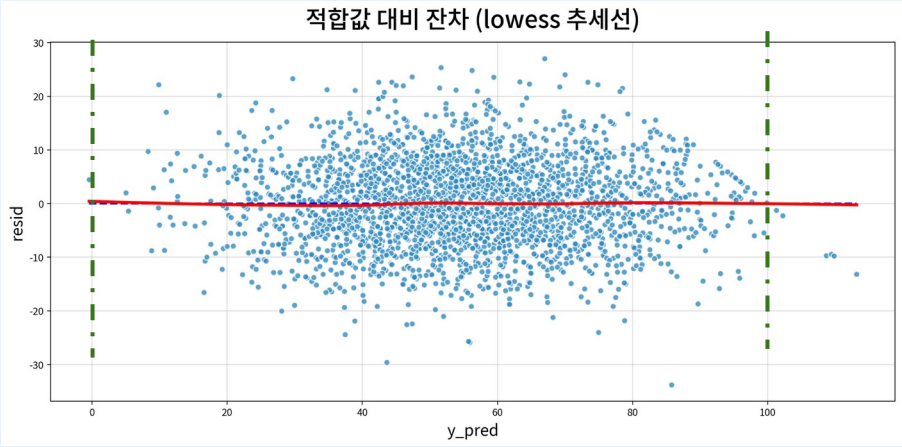
최종 모델의 회귀분석 가정 검정

1 선형성

✓ 만족

Ramsey RESET = 0.1822 · p = 0.670

귀무가설을 기각하지 못함 → 선형성 위배 근거 없음
다만 예측값이 실제 점수 범위 (0~100) 를 벗어나는 구간 존재 → 절단 효과 (p.39 한계 참조)

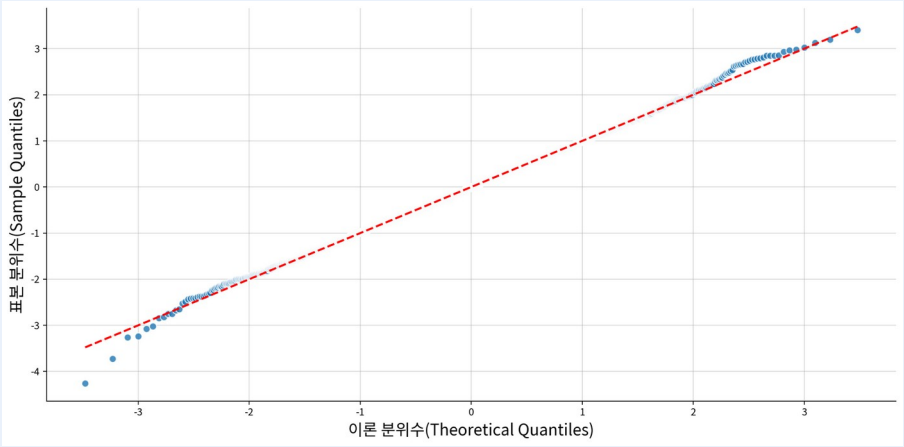


2 정규성

✓ 만족

Kolmogorov–Smirnov = 0.0148 · p = 0.583

KS 및 Q-Q plot 상 심각한 이탈 없음 → 정규성 위배 근거 없음



3 등분산성

✓ 만족

Breusch–Pagan LM = 13.41 (p = 0.708) · F = 1.04 (p = 0.709)

귀무가설을 기각하지 못함 → 등분산성 위배 근거 없음

4 독립성

✓ 만족

Durbin–Watson = 1.957

잔차 자기상관 없음 → 독립성 위배 근거 없음

최종 모형 유의성 및 설명력

n	F(17, 2719)	p
2,737	721.87	< 0.001

R^2	Adj. R^2	Durbin-Watson
0.819	0.817	1.957

독립변수 17 개를 적용한 다중선형회귀 결과 모형은 통계적으로 유의하였으며 , final_exam_score 종속변수 분산의 약 81.9% 를 설명한다 .

※ 본 데이터는 실제 학생을 관찰한 자료가 아닌 합성 데이터이다 .
따라서 높은 R^2 에는 데이터 생성 과정에서 의도된 변수 간 관계가 반영되었을 가능성이 있으며 , 이를 실제 학생 데이터에서의 설명력이나 예측 성능으로 그대로 일반화할 수 없다 .

회귀계수 해석

다른 독립변수 값이 모두 **동일**하다고 **가정**하고 해석 진행 .

1. **일반 연속형 변수** = **X** 가 **1 단위** 높은 학생은 final_exam_score 가 **평균 B 점 높거나 낮게** 나타났다 .
2. **1~10 척도 변수** = **X** 의 **응답 점수**가 **1 점** 높은 학생은 final_exam_score 가 **평균 B 점 높거나 낮게** 나타났다 .

* 최대 VIF = 1.13 (더미변수로 인해 소폭 변동)

독립변수	단위 · 기준	B	표준오차 (HC3)	β	t(HC3)	p(HC3) (유의확률)
consistency_score	1~10 점	2.1051	0.0541	0.3231	38.95	<0.001
study_hours_per_day	시간 / 일	3.9530	0.1070	0.3126	36.94	<0.001
focus_score	1~10 점	1.9806	0.0540	0.3045	36.66	<0.001
procrastination_index	1~10 점	-1.9713	0.0534	-0.3040	-36.93	<0.001
mental_state (Burnout)	기준 =Balanced	-9.8202	0.3747	-0.2289	-26.21	<0.001
burnout_risk	1~10 점	-1.4888	0.0533	-0.2273	-27.91	<0.001
motivation_level	1~10 점	1.4093	0.0541	0.2161	26.06	<0.001
revision_efficiency	1~10 점	1.3716	0.0519	0.2128	26.43	<0.001
stress_level	1~10 점	-1.2619	0.0525	-0.1960	-24.03	<0.001
assignment_completion_rate	%(완료율)	0.2033	0.0086	0.1916	23.73	<0.001
mental_state_3 (Focused)	기준 =Balanced	7.6919	0.3804	0.1766	20.14	<0.001
social_media_hours	시간 / 일	-2.1085	0.1055	-0.1669	-19.99	<0.001
attendance_percentage	%(출석률)	0.2050	0.0108	0.1588	19.04	<0.001
deep_work_sessions (6~7 회)	기준 =0~5 회	6.0373	0.3553	0.1402	16.99	<0.001
doomscrolling_before_sleep (Yes)	기준 =No	-4.8598	0.3062	-0.1304	-15.87	<0.001
financial_stress	1~10 점	-0.7927	0.0542	-0.1213	-14.63	<0.001
sleep_hours	시간 / 일	1.7447	0.1284	0.1110	13.59	<0.001

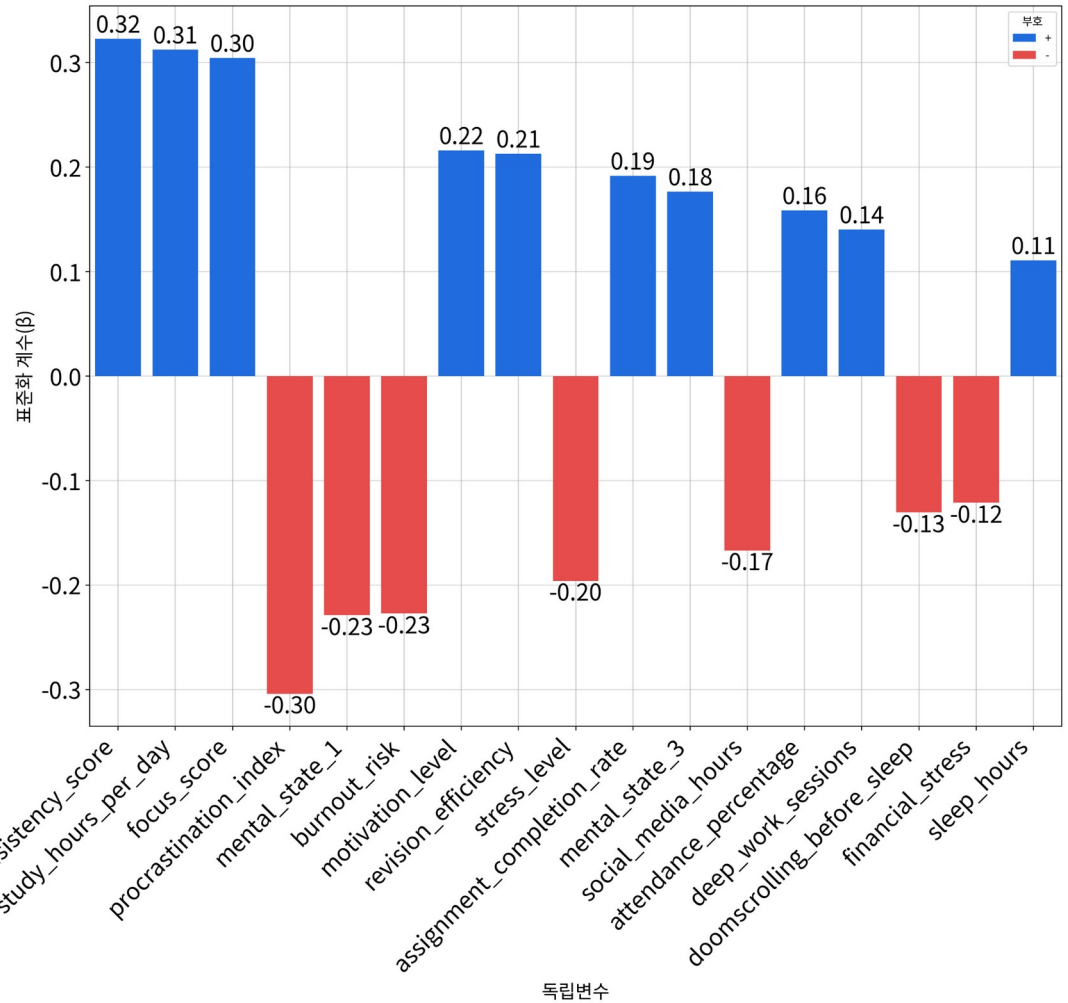
연속형 범주형

범주형 변수 해석

- mental_state = Burnout → Balanced 그룹 대비 약 9.8 점 낮음
- mental_state = Focused → Balanced 그룹 대비 약 7.7 점 높음
- *mental_state 의 Distracted 는 Balanced 와 통계적으로 구분되지 않아 (p=0.999, 평균 차이 0.15 점) 기준집단에 병합함 .
- deep_work_sessions 6~7 회 → 0~5 회 대비 약 6.0 점 높음
- doomscrolling 하는 집단 → 안 하는 집단 대비 약 4.8 점 낮음

최종 모형에서의 기말고사 점수 관련성 (표준화계수 β)

consistency_score, **study_hours_per_day** 가 final_exam_score 에 **상대적**으로 **큰 관련성**을 보인 **변수**임을 확인할 수 있다 . (표준화계수 절댓값 기준)



EDA· 추론통계와 회귀분석 결과 비교

단변량 관계와 **다중회귀 결과**가 대체로 **일관**되게 나타났다 .
다만 이는 독립변수 간 **상관이 거의 없어** (최대 VIF = 1.13) 일관된 결과를 보인 것으로 , 실제 데이터에서는 **흔치 않은 구조**이다 .

변수명	EDA· 추론통계 분석 결과	다중선형회귀분석 결과
consistency_score (꾸준함 점수)	연속형 변수 중 시험 점수와 가장 높은 양의 상관 (ρ=0.326)	표준화 계수 (β=0.323) 가 가장 높음 . (= 종속변수에 미치는 상대적 영향력이 가장 큼)
mental_state (심리 상태)	Focused > Balanced≈Distracted> Burnout - ANOVA 효과크기 중간 수준 .	Focused 그룹이 Balanced 그룹보다 약 7.7 점 높음 . Burnout 그룹이 Balanced 그룹보다약 9.8 점 낮음 .
deep_work_sessions (집중한 횟수)	단순 상관은 약함 . ANOVA 검정 시 유의 (p<0.001) 했으며 , 0~5 회 구간 평탄 , 6~7 회 상승의 임계점형 패턴 .	6,7 그룹이 약 6.0 점 높음 .
doomscrolling_before_sleep (무한 스크롤 여부)	둠스크롤 집단의 기술통계상 평균 차이는 약 5.4 점 .	무한 스크롤 하지 않는 그룹에 비해 약 4.8 점 낮음 .

05

결론

핵심 질문 · 시사점 · 한계점 및 후속 연구

핵심 질문 답변

Q1. 학습 습관 , 심리 상태 , 생활 습관 변수는 기말고사 점수와 어떤 관계를 보이는가 ?

학습 습관과 관련된 변수들 [**꾸준함 점수** (ρ=0.323), **공부시간** (ρ=0.306), **집중도 점수** (ρ=0.285), **미루기 지수** (ρ=-0.277)] 이 심리 상태나 생활 습관 관련 변수들에 비해 높은 상관관계를 보였다 .
심리 상태와 관련된 변수인 **번아웃 위험** (ρ=-0.252) 과 **학습동기 수준** (ρ=0.201), **스트레스 수준** (ρ=-0.178) 도 상대적으로 높은 상관관계를 나타냈다 .
생활 습관과 관련된 변수인 **SNS 사용시간** (ρ=-0.182) 이 성적과 유의한 음의 상관관계를 지닌 것으로 나타났으며 , 집단 간 차이 검정 (Mann-Whitney U) 결과 **취침 전 스마트폰을 사용**하는 집단이 사용하지 않는 집단에 비해 성적이 유의하게 낮은 것으로 나타났다 .

Q2. 여러 요인을 동시에 고려했을 때에도 상관분석 결과와 비교해 기말고사 점수와 관련성이 유지되는 변수는 무엇인가 ?

상관분석에서 효과크기 가장 높았던 **꾸준함 점수** (β=0.323), **공부시간** (β=0.313), **집중도** (β=0.305), **미루기 지수** (β=−0.304) 는 다중선형 회귀 결과에서도 상위권을 유지 하며 강한 상대적 영향력을 보여주었다 . 나머지 변수들 또한 순위의 변동은 있었으나 여러 요인을 동시에 통제한 상태에서도 상관분석 결과와 일관된 경향성을 보였으며 , 성적을 설명하는 독립적인 기여도가 여전히 유지되고 있음을 확인하였다 .

Q3. 최종 회귀모형은 기말고사 점수의 변동을 어느정도 설명하며 , 해석 가능한 범위와 한계는 무엇인가 ?

최종 모형의 결정계수 (R^2) 는 약 81.9% 로 , 분석 표본의 점수 변동을 높은 수준으로 설명했지만 , 이는 합성 데이터 내에 존재하는 조건부 관련성과의 적합도를 의미할 뿐 , 인과관계와 새로운 학생에 대한 예측 성능까지 보장하지는 않는다 .

선행 연구와의 비교

1. 조사연구 (이기종 · 곽수란 , 2010) 에서는 공부시간을 학업성취의 핵심적인 요인으로 다룬바 있다 .

본 분석 결과 , **공부시간** (study_hours_per_day) 은 **학업 성취**에 **상대적으로 높은 관련성**이 있는 것으로 확인되었다 (β = 0.313).
이는 **공부시간**을 **학업성취의 핵심 요인**으로 **제시**한 이기종 · 곽수란 (2010) 의 연구 결과와 일치한다 .
따라서 공부시간과 학업성취 간에는 유의한 상관 관계가 존재할 가능성이 높다고 판단된다 .

2. 한국교육문제연구 (안도희 · 최혜림 , 2012) 에서는 학업동기와 가족지원이 학업성취와 관련되어 있는 것으로 보고하였다 .

본 분석 결과 , **학습동기수준** (motivation_level) 은 **학업 성취도와 유의한 상관**을 보이는 것으로 나타나 (β = 0.216), **선행 연구의 결과와 일치**하였다 .
반면 , **가족 지원** (family_support) 의 경우 학업 성취도와 통계적으로 **유의한 상관성을 보이지 않아** (p>0.05), **선행연구의 보고와 다른 결과**를 나타냈다 .

분석 시사점

1. 기말고사 성적과 영향 요인 간의 다차원적 복합 관계

‘ **기말고사 성적**’ (final_exam_score) 은 특정 **단일 요인**이 아닌 , **다양한 영역의 변수**들과 복합적인 상관관계를 형성하고 있다 .
기말고사 성적에 미치는 상대적 영향력이 가장 큰 변수는 ‘꾸준함’ (β = 0.323) 과 ‘공부 시간’ (β = 0.313) 으로 나타났으나 , 집중도 , 멘탈 상태 , 번아웃 위험 등 **다른 여러 변수**들도 각각 **유의한 독립적 기여도**를 보이기 때문에 , 두 요인만으로 기말고사 성적의 변동을 완전히 설명할 수는 없다 .
→ 학업 성취 수준에 대한 정확한 진단을 위해서는 특정 단일 지표에 의존하기보다 **다양한 영역의 지표**들을 **종합 분석**하는 다각적 접근이 필요함을 시사한다 .

2. 성적은 통제 가능한 ' 학습 습관 ' 이 중요

나이 (age)· 성별 (gender)· 거주지 유형 (city type) 과 같이 변경이 어려운 **‘인구통계적 변수’**가 성적에 미치는 영향은 낮았던 반면 ,
꾸준함 (consistency_score)· 공부시간 (study_hours_per_day)· 집중도 점수 (focus_score)· 미루기 지수 (procrastination_index) 와 같이 ‘ **학습 습관’**에 관련된 **통제가능한 변수**들은 성적과 상대적으로 큰 상관관계를 보였다 .
→ 후천적인 노력에 의한 학습 습관 개선이 학업 성취도 향상에 도움이 될 수 있다는 것을 시사한다 .

학습 지원 방향 제언

※ 아래 내용은 개입 효과가 검증된 처방이 아닌 , 최종 회귀모형에서 상대적으로 관련성이 크게 나타난 조절 가능 요인을 바탕으로 한 우선 검토 방향 .

1. 공부 시간과 공부 지속성 (꾸준함) 관리

공부시간뿐 아니라 **꾸준함** , **미루기** 성향도 상대적으로 큰 관련성을 보였다 .
따라서 단순히 총 공부시간만 늘리기보다 , **일정한 학습시간을 확보하고 학습 과제를 꾸준히 완료**해내는 자기관리 방식을 고려할 필요가 있다 .

[적용 예시]

공부 계획을 '시간'단위가 아닌 **'과제 (Task)' 단위**로 나누어 여러 단계의 중간 목표 설정을 통해 학습의 지속성을 높이는 방식을 검토해본다 .

2. 집중력을 유지하는 학습환경 조성

집중도는 점수와 비교적 큰 양의 관련성을 보였고 , SNS 사용시간과 취침 전 스마트폰 사용은 음의 관련성을 보였다 .
따라서 집중 학습 시간에는 **SNS 와 알림을 차단**하고 , **취침 전 스마트폰 사용을 줄이는 '학습 환경 조성'** 방안을 고려할 수 있다 .

3. 번아웃 · 스트레스 상태 조기 점검

Burnout 집단은 Balanced 집단보다 평균점수가 통계적으로 유의하게 낮았고 , 번아웃 위험과 스트레스 수준도 점수와 음의 관련성을 보였다 .
따라서 학습시간 확대만 강조하기보다 **번아웃 위험성을 주기적으로 점검**하고 , **적절한 휴식과 상담 지원 등을 통해 스트레스를 관리**할 필요가 있다 .

분석 한계점 · 후속 연구

미설명 분산 18.1% · RMSE = 7.94 점 · MAE ≈ 6.35 점

- 최종 모형은 평균 절대 오차 (MAE) 6.35 점 , 평균 제곱근 오차 (RMSE) 7.94 점을 보이며 , 예측값과 실제 성적 간에 일정 수준의 오차가 존재한다는 한계가 있다 .
- 측정되지 않은 요인 , 비선형 관계 , 측정 오차 등으로 인해 18% 의 미설명 분산이 존재하는 것으로 보인다 .

주요 한계

① **정제된 합성데이터**
개념 상 관련성이 높은 변수들 사이에서도 상관이 매우 낮게 나타남
합성 데이터의 생성 방식이 현실의 복합적인 변수 관계를 반영하지 못했을 가능성을 시사 → 분석 결과 일반화 어려움

② **횡단면 데이터**
특정 한 시점의 데이터이기 때문에 인과 관계 판단 불가

③ **데이터의 주관성**
1~10 척도의 설문형 데이터가 다수 포함 . 응답자의 편향이 반영되기 쉬워

객관성과 타당성이 떨어질 수 있음

④ **과적합 (Overfitting) 우려**
동일한 데이터로 EDA, 변수 그룹화 , 최종 모형 선정과 성능 계산을 모두 수행해 , 모형 성능이 실제보다 과대평가됐을 가능성이 있음

⑤ **종속변수 절단 (censored)**
final_exam_score 값은 0~100 사이로 제한되지만 다중회귀모형은 0 미만 ,
100 초과 범위까지 예측함 (p.29 잔차 플롯). 이로인해 양 끝 구간에서 예측이 체계적으로 어긋남 .

✓ 도출 가능한 결론

1. 독립 - 종속변수 연관성	변수의 연관성과 관계 방향 , 표준화 계수를 통한 영향력 비교
2. 모형 적합도	여러 변수를 함께 고려한 모형의 표본 내 설명력
3. 평균적 경향성	여러 변수가 종합적으로 작용하는 평균적인 관계성 도출

✗ 말할 수 없는 것

1. 인과 설명 x	행동변화가 성적 상승으로 이어진다는 인과 효과 해석 어려움
2. 미측정 외부 요인	교육 정책 · 상담 지원 등 측정되지 않은 효과 파악 어려움
3. 개인 단위 예측 불가	집단적 분석일뿐 개인 점수에 대한 예측은 어려움

후속 연구

① **실제 학생 데이터를 통한 모형의 일반화 성능 검증**
실제 학생 데이터로도 주요 회귀계수와 설명력이 재현되는지 확인

② **시간 흐름을 포함해 분석**
여러 학기의 데이터 변수로 성적의 시간적 선후관계 , 변화 확인

③ **객관적 측정 데이터 사용**
기존 척도 변수대신 객관적 도구로 측정된 변수를 사용해 분석 진행 .

④ **비선형 모형으로 확장**
머신러닝을 이용해 비선형 모형까지 분석 확장 . 선형모형과 성능 비교

06

참고문헌 · 부록

참고 문헌 · 부록

참고문헌

1. 이기종 , 곽수란 (2010). 학업성취 변화에 영향을 미치는 공부시간 효과 추정 . *조사연구 , 11(1)*, 43-61. (https://scienceon.kisti.re.kr/srch/selectPORSrchArticle.do?cn=JAKO201031559294986)

2. 안도희 , 최혜림 (2012). 고등학생의 학업 동기 및 사회적 지지와 학업 성취와의 관계 . *한국교육문제연구 , 30(2)*. (https://www.dbpia.co.kr/journal/articleDetail?nodeId=NODE07193070)

3. Huh I, Gim J. Exploration of Likert scale in terms of continuous variable with parametric statistical methods. BMC Med Res Methodol. 2025 Sep 29;25(1):218. doi: 10.1186/s12874-025-02668-1. PMID: 41023822; PMCID: PMC12482090. (https://pmc.ncbi.nlm.nih.gov/articles/PMC12482090/)

4. 데이터 : aiexplorer77. Student Academic Performance Prediction [Data set]. Kaggle, MIT License. (https://www.kaggle.com/datasets/aiexplorer77/academic-performance-prediction)

부록

T-test(2)

ANOVA(5)

가정검정 — physical_activity_hours

구분	검정	통계량	p-value	충족 여부
0	normaltest	2.2368	0.3268	충족 (True)
1	normaltest	7.5330	0.0231	위배 (False)
Levene	**equal_var**	**0.3917**	**0.5315**	충족 (True)

가정검정 — doomscrolling_before_sleep

구분	검정	통계량	p-value	충족 여부
NO	normaltest	10.4709	0.0053	위배 (False)
Yes	normaltest	1.6011	0.4491	충족 (True)
Levene	**equal_var**	**3.4914**	**0.0618**	충족 (True)

가정검정 — mental_state

구분	검정	통계량	p-value	충족 여부
Balanced	normaltest	2.9634	0.2272	충족 (True)
Burnout	normaltest	3.4187	0.1810	충족 (True)
Distracted	normaltest	2.2745	0.3207	충족 (True)
Focused	normaltest	2.5555	0.2787	충족 (True)
Bartlett	**equal_var**	**0.4335**	**0.9332**	충족 (True)

가정검정 — city_type

구분	검정	통계량	p-value	충족 여부
Rural	normaltest	5.4014	0.0672	충족 (True)
Semi-Urban	normaltest	4.6666	0.0970	충족 (True)
Urban	normaltest	0.8803	0.6439	충족 (True)
Bartlett	**equal_var**	**4.8603**	**0.0880**	충족 (True)

가정검정 — learning_style

구분	검정	통계량	p-value	충족 여부
Audio	normaltest	4.5236	0.1042	충족 (True)
Practical	normaltest	3.8587	0.1452	충족 (True)
Reading	normaltest	1.0729	0.5848	충족 (True)
Visual	normaltest	4.3816	0.1118	충족 (True)
Bartlett	**equal_var**	**4.0483**	**0.2563**	충족 (True)

가정검정 — career_goal

구분	검정	통계량	p-value	충족 여부
Arts	normaltest	4.5405	0.1033	충족 (True)
Business	normaltest	2.9509	0.2287	충족 (True)
Engineering	normaltest	4.8511	0.0884	충족 (True)
Medical	normaltest	0.8217	0.6631	충족 (True)
Research	normaltest	0.3405	0.8434	충족 (True)
Bartlett	**equal_var**	**3.3630**	**0.4990**	충족 (True)

가정검정 — deep_work_sessions

구분	검정	통계량	p-value	충족 여부
0	normaltest	0.4864	0.7841	충족 (True)
1	normaltest	0.2510	0.8821	충족 (True)
2	normaltest	3.2810	0.1939	충족 (True)
3	normaltest	0.6459	0.7240	충족 (True)
4	normaltest	0.9194	0.6315	충족 (True)
5	normaltest	1.1589	0.5602	충족 (True)
6	normaltest	2.4046	0.3005	충족 (True)
7	normaltest	4.7106	0.0949	충족 (True)
Bartlett	**equal_var**	**3.1674**	**0.8691**	충족 (True)

부록

결측 행 vs 비결측 행 : 30 개 변수 중 27 개 차이 없음 , 3 개는 p < .05 이나 Bonferroni 보정 (.05/30) 후 모두 비유의 → 결측은 무작위에 가까움

변수	검정	p-value	판정
age	Mann-Whitney U	0.790	차이 없음
gender	χ^2 독립성	0.604	차이 없음
city_type	χ^2 독립성	0.476	차이 없음
study_hours_per_day	Mann-Whitney U	0.010	유의 (보정 후 비유의)
deep_work_sessions	Mann-Whitney U	0.957	차이 없음
assignment_completion_rate	Mann-Whitney U	0.182	차이 없음
attendance_percentage	Mann-Whitney U	0.426	차이 없음
● social_media_hours	Mann-Whitney U	0.081	차이 없음
doomscrolling_before_sleep	Mann-Whitney U	0.112	차이 없음
notification_distractions	Mann-Whitney U	0.564	차이 없음
ai_tool_usage_hours	Mann-Whitney U	0.035	유의 (보정 후 비유의)
gaming_hours	Mann-Whitney U	0.491	차이 없음
stress_level	Mann-Whitney U	0.326	차이 없음
motivation_level	Mann-Whitney U	0.507	차이 없음
● focus_score	Mann-Whitney U	0.292	차이 없음

변수	검정	p-value	판정
procrastination_index	Mann-Whitney U	0.815	차이 없음
mental_state	χ^2 독립성	0.820	차이 없음
● sleep_hours	Mann-Whitney U	0.588	차이 없음
caffeine_intake	Mann-Whitney U	0.284	차이 없음
physical_activity_hours	Mann-Whitney U	0.870	차이 없음
internet_quality	Mann-Whitney U	0.006	유의 (보정 후 비유의)
family_support	Mann-Whitney U	0.225	차이 없음
financial_stress	Mann-Whitney U	0.064	차이 없음
learning_style	χ^2 독립성	0.335	차이 없음
career_goal	χ^2 독립성	0.061	차이 없음
productivity_after_midnight	Mann-Whitney U	0.562	차이 없음
revision_efficiency	Mann-Whitney U	0.213	차이 없음
burnout_risk	Mann-Whitney U	0.565	차이 없음
consistency_score	Mann-Whitney U	0.126	차이 없음
final_exam_score	Mann-Whitney U	0.691	차이 없음

● 실제 결측 발생 변수 (각 60 건): social_media_hours · focus_score · sleep_hours | 검정 : 결측이 있는 행 (177) vs 없는 행 (2,823) — 연속형 Mann-Whitney U, 범주형 χ^2 독립성

END

감사합니다

장범진 · 김민재 · 최용준 · 김가람

(ITWILL- 빅데이터 분석 -56 기 -3 조)